MESSI10

Citi Bike mijn deel

Raoul Buffels

Dataonderzoek, modellen en de Citi Bike-applicatie

Team: Jorre Van Dyck, Milan Wouters,
Andrew Noeyens en Raoul Buffels

Wat ik in de brondata tegenkwam

175 ZIP-bronnen

NYC en Jersey City, apart verwerkt

323,8 miljoen NYC-records

Technische dekking: juni 2013–augustus 2026
EDA: uitsluitend vóór mei 2026

Wat mij opviel

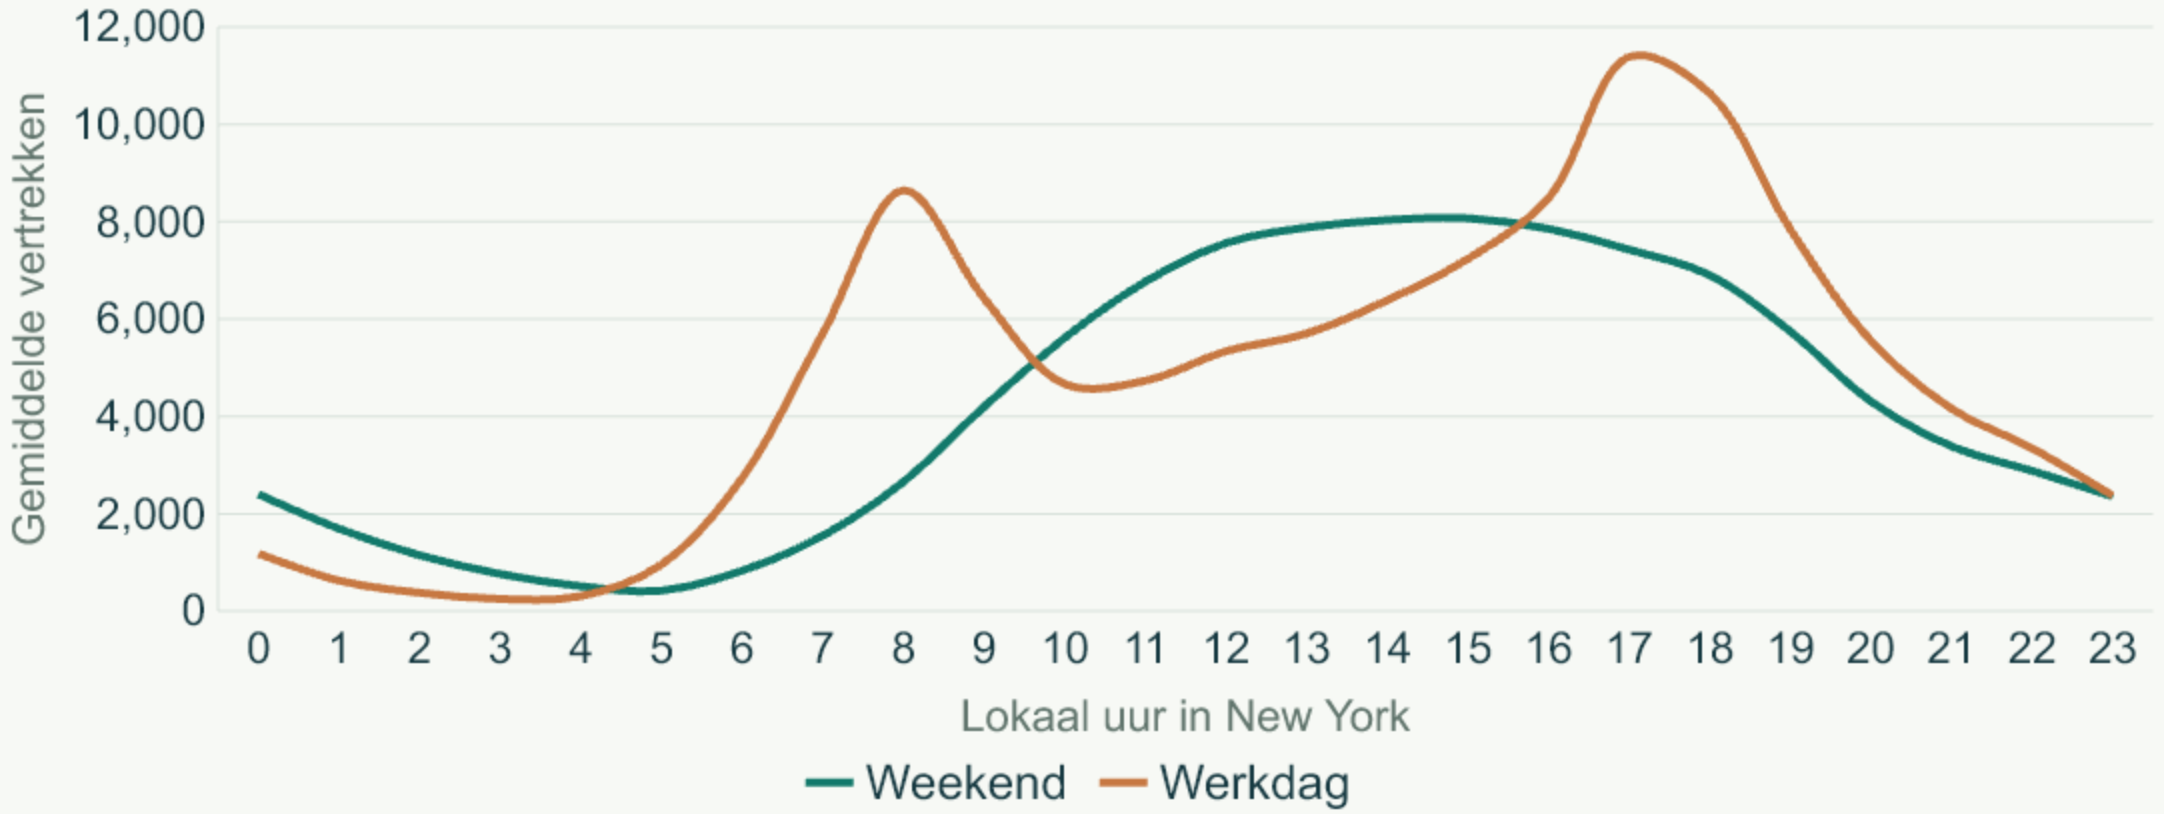
Bronarchieven overlappen

Schema’s veranderen door de jaren

Lange geregistreerde duur vraagt uitleg

Een missing eindstation wist de start niet

Gebruik volgt het uur en de weekdag



Ontwikkeling vanaf 2023 tot april 2026. De lijnen tonen geregistreerde ritstarts.

Weekherhaling ondersteunt het uurdoel

0,856

gemiddelde weekcorrelatie

95%-interval: 0,837–0,876
Holm-p ≈ 0,00015

De toets

H0: gemiddelde correlatie = 0
H1: gemiddelde correlatie ≠ 0

43 blokken van vier weken
Alpha = 0,05

Doel: de 24 uurvakken van morgen voorspellen om 00:00 New York-tijd

MODELLEN

Alle modellen krijgen dezelfde modeldata

14 features: kalender en afgesloten historie

Daglags en rolling kennen alleen volledige dagen vóór de voorspeldag

Deel	Periode	Gebruik
Training	Vóór mei 2026	Fit en chronologische CV
Validatie	Mei–juni 2026	Vergelijking en modelkeuze
Eindtest	Juli–augustus 2026	Bestaande eindbeoordeling

112.872 trainingsrijen en 1.464 validatierijen. Vijf folds van 28 dagen.

MODELLEN

Random Forest valideert het beste



RF getuned: 1.940,49 ritten/uurvak. 31,34% lagere RMSE dan de weekbaseline.

PyCaret vergelijkt dezelfde basismodellen. Deze rangschikking gebruikt validatie.

Snelle training en generalisatie verschillen

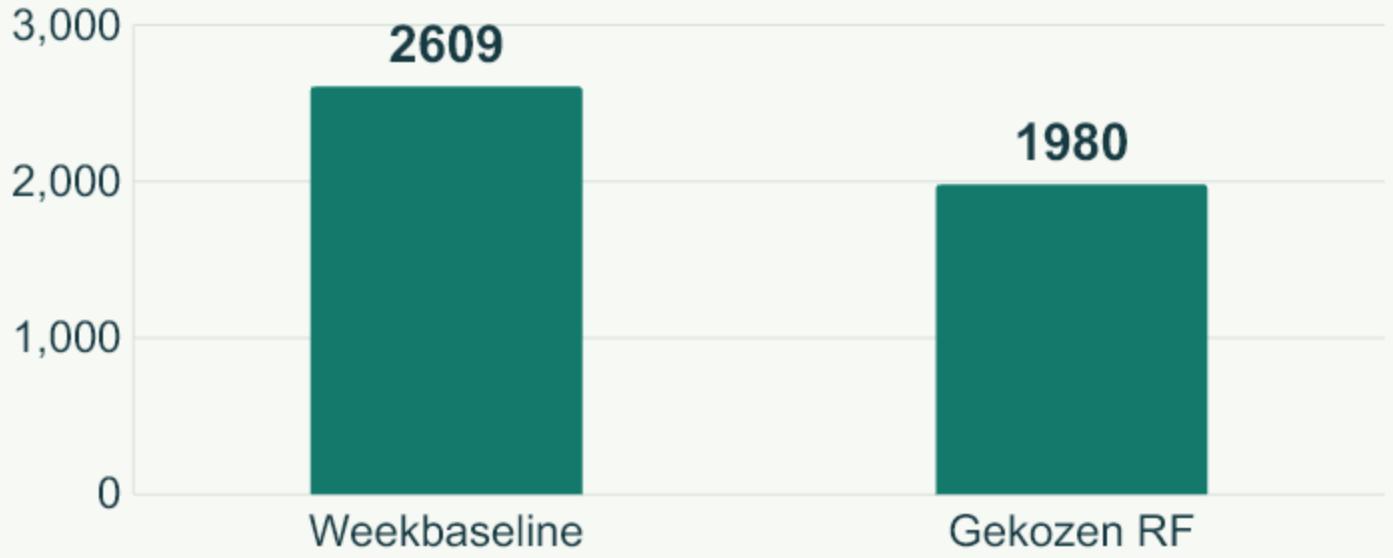
Model	Train-RMSE	Validatie-RMSE	Fit op deze pc
Ridge	1.022	1.982	0,05 s
LightGBM	778	1.952	0,72 s
Random Forest	684	1.946	37,92 s
RF getuned	536	1.940	71,24 s

RF-tuning: slechts 0,27% extra validatiewinst

Circa 647 MiB voor het finale oorspronkelijke artefact

CONCLUSIE

De bestaande eindtest bevestigt winst



24,12%

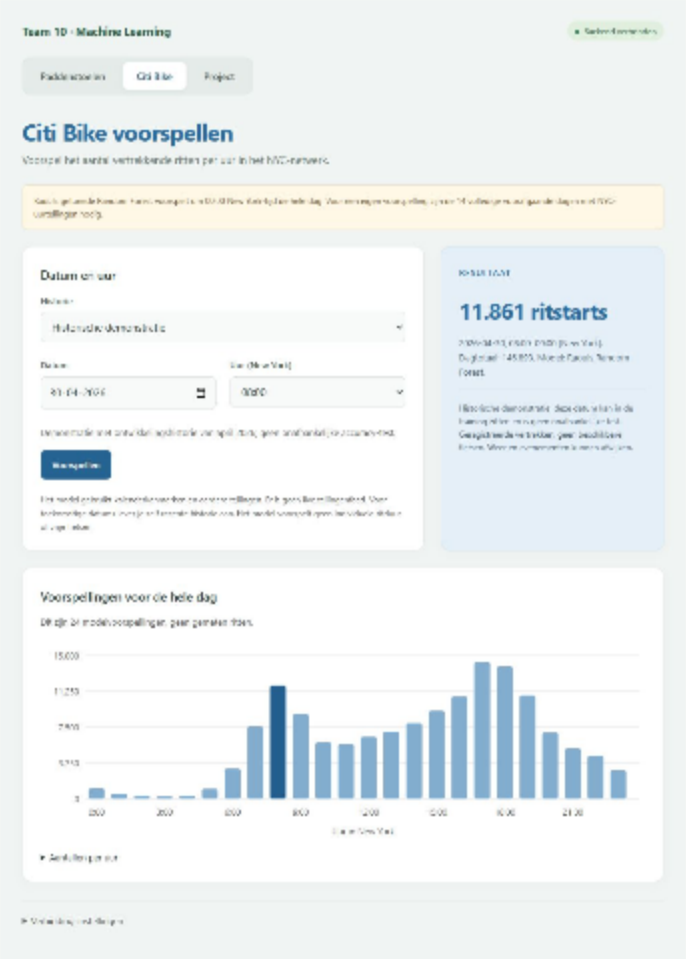
lagere RMSE dan de baseline

MAE: 1.076,23
R^2: 0,828

Juli–augustus 2026. Alleen de vooraf gekozen winnaar en baseline.

De test blijft een eindrapport. Twee zomermaanden beperken de generalisatieclaim.

Mijn resultaat en de volgende stap



Werkende frontend en API

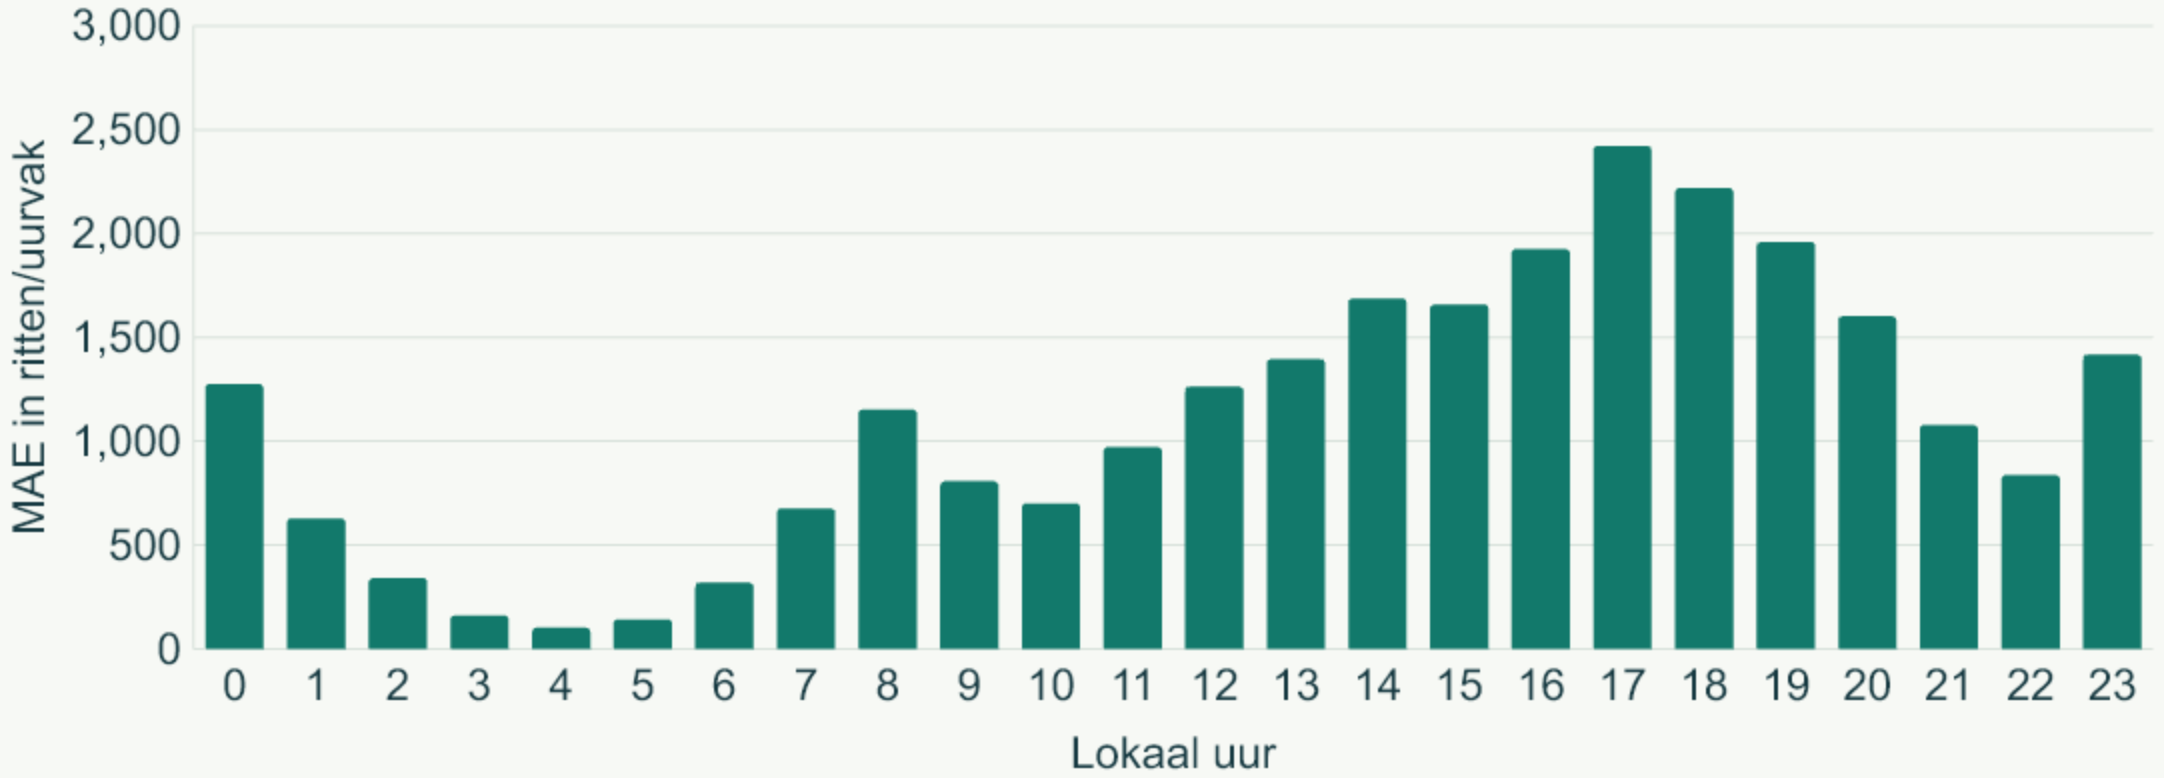
Dezelfde voorspelfunctie als offline

Gecontroleerde lokale RF-hertraining met een apart modelartefact

Nog te regelen

Runnerregistratie en een GitHub-run
Live modelupdate
AWS-cloudbewijs in het groepsproject

Grootste fouten blijven rond drukke uren



Residual = actual − prediction. De foutenanalyse gebruikt mei–juni-validatie.

Keuzes die ik mondeling kan uitleggen

Waarom chronologisch?

De toekomst mag het verleden niet beïnvloeden

Waarom deze RF?

De vooraf vastgelegde 1%-regel vergelijkt modeltypen

Waarom tijdsblokken?

Ritten en naburige uren zijn afhankelijk

Waarom geen nieuwe tuning?

Een nieuwe keuze vraagt een nieuwe onafhankelijke eindtest